Apache Spark

Andrés Gómez Ferrer
andresgomezfrr@gmail.com

Spark SQL

Spark SQL: Basics

- Spark SQL es un modulo para el procesamiento de datos estructurados.
- Las interfaces proporcionan mayor información sobre la estructura y la computación de los datos que la API de Spark RRD.
- Existen varias formas para trabajar con Spark SQL:

- Dataframe: Conjunto de datos organizados en columnas. Es equivalente a una tabla relacional. Pueden ser construidos desde: ficheros estructurados, tablas en Hive, base de datos externas, o RRDs existentes. Scala/Java/Python/R

- Dataset: Conjunto de datos distribuidos, permite usar Spark SQL con los beneficios de los RDDs: tipado fuerte, transformaciones funcionales, etc. Scala/Java

- SQL: Lenguaje con sintasix SQL

Spark SQL: Base Project

- Para empezar un proyecto de Spark, necesitamos añadir sus dependencias en nuestro proyecto de sbt en el IDE.
- **IMPORTANTE: SCALA 2.12.12**

```
libraryDependencies ++= Seq(
  "org.apache.spark" %% "spark-core" % "3.0.1”,
  "org.apache.spark" %% "spark-sql" %  "3.0.1”
)
```

- Una vez tenemos las dependencias, podemos crear un objeto principal con un método *main*, donde crearemos un nuevo contexto de spark.
- Desde este punto podemos ejecutar en el play del IDE y ejecuta spark en modo local[1], modo local, usando 1CPU de la maquina.
- **En este caso usaremos una instancia de SparkSession en lugar de SparkContext**

```
package io.keepcoding.spark.sql
import org.apache.spark.sql.SparkSession

object SparkSqlBaseProject {
  def main(args: Array[String]): Unit = {
    val spark = SparkSession
      .builder()
      .appName("Spark SQL KeepCoding")
      .getOrCreate()

    import spark.implicits._
    // <code>

    spark.close()
  }
}
```

Exercise 1

Read Multiple Data Sources

- CSV
- JSON

Exercise 2

Spark SQL: DataFrame Basics

Apache Parquet

- El formato Parquet es un formato de almacenamiento en columnas enfocado en optimizar el procesamiento y modelado de datos.

- Un fichero de parquet esta compuesto por tres piezas:
  - **Row Group**: conjunto de filas en formato columnar.
  - **Column chunk:** datos de una columna en un grupo, se puede leer de manera independiente para optimizar las lecturas.
  - **Page**: almacenamiento de los datos.

- Spark optimiza las lecturas:
  - Permite leer los distintos row group de manera independiente, asignado estos datos a distintas tareas, que son distribuidas en el cluster.
  - Si seleccionamos unas columnas especificas, el filtro es empujado hacia el lector de parquet permitiendo leer únicamente esas columnas.

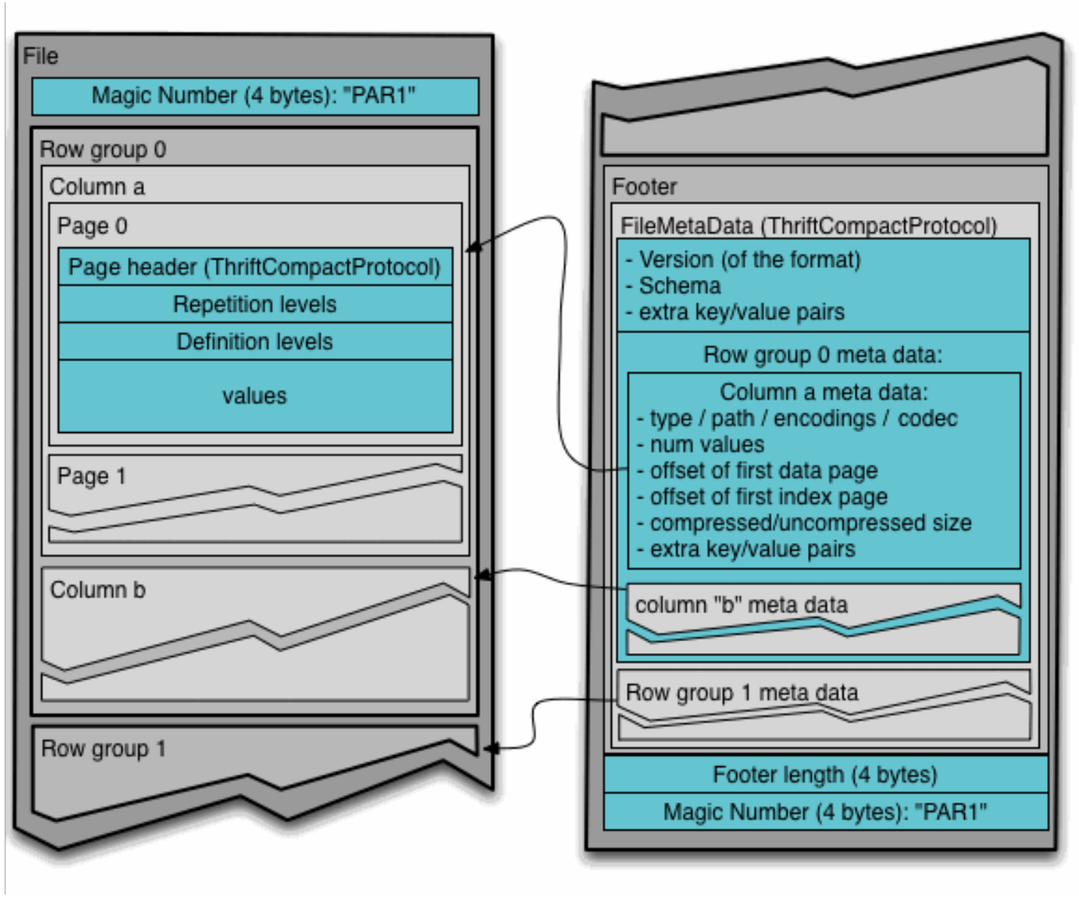

Utilizado para procesamiento en BATCH

https://parquet.apache.org/

SparkSQL: Apache Parquet

- Spark soporta de manera nativa la lectura y escritura en ficheros Parquet.

- Leyendo Parquet las columnas son marcadas como *nullable*, por razones de compatibilidad.

PARTICIONADO

- Parquet permite el particionado de datos para optimizar sus lecturas.
- Los datos son almacenados en distintos directorios, codificando los valores en el nombre del directorio, para cada partición.

```
path
└── to
    └── table
        ├── gender=male
        │   ├── ...
        │   │
        │   ├── country=US
        │   │   └── data.parquet
        │   ├── country=CN
        │   │   └── data.parquet
        │   └── ...
        └── gender=female
            ├── ...
            │
            ├── country=US
            │   └── data.parquet
            ├── country=CN
            │   └── data.parquet
            └── ...
```

Apache AVRO

- Formato binario para serialización de datos.
- **Funciona con schemas**: cuando se lee un AVRO, el schema con el que se escribió esta siempre presente. Permitiendo no producir overheads y realizar la serialización rápida y con poco coste de tamaño.
- Normalmente cuando se almacena un fichero de AVRO, el esquema se guarda con el, y de esta manera siempre esta presente. Aunque puede ser leído por otro **schema compatible**.
- Los schemas de AVRO están escritos en formato JSON.

Utilizado para procesamiento en Streaming, soporta procesamiento BATCH en ficheros

```
{
 "type": "record",
 "name": "userInfo",
 "namespace": "my.example",
 "fields": [
  { "name": "username", "type": "string", "default": "NONE" },
  { "name": "age", "type": "int", "default": -1 },
  { "name": "phone", "type": "string", "default": "NONE" },
  { "name": "housenum", "type": "string", "default": "NONE" },
  { "name": "address", "type":
   {
    "type": "record", "name": "mailing_address", "fields":
     [
      { "name": "street", "type": "string", "default": "NONE" },
      { "name": "city", "type": "string", "default": "NONE" },
      { "name": "state_prov", "type": "string", "default": "NONE" },
      { "name": "country", "type": "string", "default": "NONE" },
      { "name": "zip", "type": "string", "default": "NONE" }
     ]
   }, "default": {}
  }
 ]
}
```

SparkSQL: Apache AVRO

- SparkSQL necesita de una extensión para poder trabajar con Avro y poder hacer .format("avro")

```
libraryDependencies += "org.apache.spark"
%% "spark-avro" % "3.0.1"
```

- Avro permite indicar el tema mediante options a la hora de hacer los read/write, mediante la propiedad **avroSchema.**

Avro type	Spark SQL type
boolean	BooleanType
int	IntegerType
long	LongType
float	FloatType
double	DoubleType
string	StringType
enum	StringType
fixed	BinaryType
bytes	BinaryType
record	StructType
array	ArrayType
map	MapType

SparkSQL: Apache AVRO

- Avro también tiene tipos lógicos para soportar estructuras de datos más complejas.

Avro logical type	Avro type	Spark SQL type
date	int	DateType
timestamp-millis	long	TimestampType
timestamp-micros	long	TimestampType
decimal	fixed	DecimalType
decimal	bytes	DecimalType

- El tipo **union** en Avro se utiliza para indicar que un campo puede tener distintos valores de tipo, spark realiza las siguientes traducciones:
  - **union(int, long) → LongType**
  - **union(float, double) → DoubleType**
  - **union(any, null) →** El equivalente en spark, pero la **columna** es marcada como **nullable.**
  - Si la union es de dos tipos distintos, son consideradas complejas y se traducen en una estructura con distintos miembros. **union(int, string) → member0 (int), member1 (string)**

Exercise 3

Read More Data Sources

- PARQUET
- AVRO

JDBC Connection

- Spark permite obtener/escribir datos desde/hacia base de datos relacionales mediante conexión JDBC.
- Necesita incluir el driver JDBC como librería adicional

```
libraryDependencies += "org.postgresql" % "postgresql" % "42.2.16"

libraryDependencies += "mysql" % "mysql-connector-java" % "8.0.21"
```

- El driver se indica mediante la opción `driver`, tanto en la lectura como escritura.
- La opción `url` es usada para indicar la cadena de conexión en formato URI.

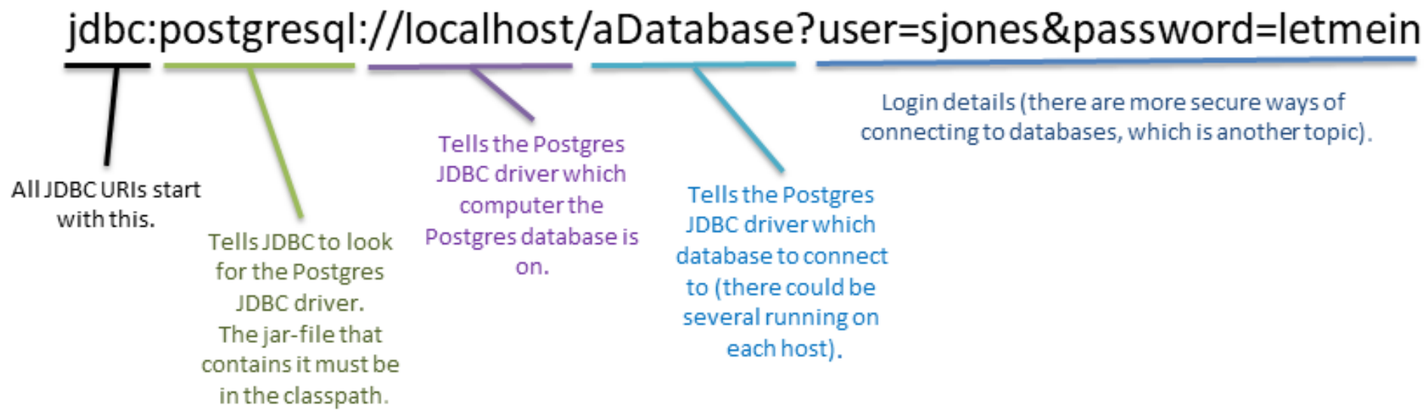

Exercise 4

Read Data From Google SQL

Exercise 5

Sensor data with SparkSQL

- DataFrame API
- SQL
- Dataset API

Exercise 6

spark-sql CLI